

Análise Exploratória de Dados — Capítulo 1

Aprendizagem Estatística CC

Soraia Pereira

17 de setembro de 2025

EDA: objetivo

Análise Exploratória de Dados (EDA) visa **caracterizar** a distribuição e a estrutura dos dados (qualidade, heterogeneidade, dependências e forma), através de resumos numéricos e visualizações gráficas, para formular hipóteses e orientar as etapas seguintes da análise/modelação.

Ciclo (Gromelund & Wickham, 2017):

1. Colocar **questões** sobre os dados.
2. Explorar com **visualização** e **medidas resumo**.
3. **Refinar** questões com base no que foi descoberto e repetir.

Nota: o processo é iterativo e guiado pelas questões; não é um procedimento único.

Tipos de variáveis

Quantitativas

- **Discretas:** contagens (ex.: $\#$ transações).
- **Contínuas:** medidas em \mathbb{R} (ex.: tempo, altura).

Qualitativas

- **Nominais:** categorias sem ordem (ex.: região, sexo).
- **Ordinais:** categorias com ordem (ex.: nível de educação).

Implicações: As medidas resumo e os gráficos adequados dependem do tipo de variáveis.

Dados de exemplo: gapminder

```
library(gapminder)  (se pretender usar em R)
```

Visualização das 6 primeiras linhas:

```
> head(gapminder)
# A tibble: 6 x 6
  country    continent year lifeExp      pop gdpPercap
  <fct>      <fct>    <int>   <dbl>     <int>     <dbl>
1 Afghanistan Asia      1952    28.8  8425333    779.
2 Afghanistan Asia      1957    30.3  9240934    821.
3 Afghanistan Asia      1962    32.0  10267083   853.
4 Afghanistan Asia      1967    34.0  11537966   836.
5 Afghanistan Asia      1972    36.1  13079460   740.
6 Afghanistan Asia      1977    38.4  14880372   786.
```

Boa prática: documente unidade das variáveis, período temporal e origem dos dados.

Medidas resumo

Localização (tendência central)

Considere a amostra (x_1, \dots, x_n) de dimensão n.

- **Média:** $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ (ponto de equilíbrio; sensível a outliers)
- **Mediana:** medida de localização que divide a distribuição "ao meio".

$$\tilde{x} = Q_{1/2} = \begin{cases} \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & \text{se } n \text{ é par} \\ x_{\left(\frac{n+1}{2}\right)}, & \text{se } n \text{ é ímpar} \end{cases}$$

onde $x_{(i)}$ é o elemento da amostra ordenada que ocupa a posição i.

- **Moda:** valor mais frequente (pouco estável em amostras pequenas).

Localização

- **Quantil de probabilidade p :** valor Q_p tal que $p \times 100\%$ dos valores da amostra são inferiores a Q_p e $(1 - p) \times 100\%$ são superiores a Q_p .

$$Q_p = \begin{cases} \frac{x_{(np)} + x_{(np+1)}}{2}, & \text{se } np \text{ é inteiro} \\ x_{([np]+1)}, & \text{se } np \text{ não é inteiro} \end{cases}$$

Os quantis mais utilizados são os quartis $(Q_{1/4}, Q_{1/2}, Q_{3/4})$.

Média vs Mediana (assimetria)

- Distribuição simétrica: $\bar{x} \approx \tilde{x}$.
- Assimetria positiva: $\bar{x} > \tilde{x}$.
- Assimetria negativa: $\bar{x} < \tilde{x}$.

Dispersão

- **Variância:** $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{\sum x_i^2 - n\bar{x}^2}{n-1}$
- **Desvio-padrão:** $s = \sqrt{s^2}$
- **Coeficiente de variação:** $CV = s/\bar{x}$
- **Amplitude:** $R = x_{(n)} - x_{(1)}$
- **Intervalo inter-quartis:** $IQR = Q_3 - Q_1$

Gráficos básicos

Gráfico de Barras

- Variáveis **nominais/ordinais**; alturas \propto frequências (absolutas/relativas).
- Ordenar barras pode clarificar.




Figura 1: Exemplo de gráfico de barras

Histograma

- Variáveis **contínuas**; barras adjacentes indicam continuidade.
- Largura de classes (*binwidth*) influencia a leitura.
- Regras úteis: *Freedman–Diaconis* $h = 2 \text{IQR} n^{-1/3}$, *Scott*, *Sturges*.




Figura 2: Exemplo de histograma

Boxplot

- Caixa: $[Q_1, Q_3]$; linha central: \tilde{x} ; bigodes até limites.
- $IQR = Q_3 - Q_1$
- **Outliers**: pontos fora de $[Q_1 - 1.5 \text{ IQR}, Q_3 + 1.5 \text{ IQR}]$.




Figura 3: Exemplo de boxplot

Qualidade dos dados

Valores em falta e outliers

Valores em falta (NA):

- Quantificar por variável
- Estratégias: análise dos dados completos, imputação simples (mediana), métodos múltiplos (quando relevante).

Outliers:

- Diagnóstico via boxplot, análise contextual.
- Tratar *com justificação*: corrigir erros, manter e usar medidas robustas, ou análises com/sem.

Associação entre variáveis

Dispersão e associação

- **Gráfico de dispersão** é a primeira ferramenta para análise da associação entre duas variáveis quantitativas.
- **Homocedasticidade:** dispersão semelhante ao longo de X .
- **Cuidado:** padrões curvilíneos, clusters e pontos influentes.

Gráfico de Dispersão (scatterplot)

- Usado para **duas variáveis quantitativas** — pares (x_i, y_i) .
- Revela forma da relação: linear/curvilínea, **direção (+/-)** e **força** (nuvem mais/menos concentrada).




Figura 4: Exemplo de gráfico de dispersão.

Coeficiente de correlação amostral de Pearson (r)

- **Mede a força e a direção da associação linear** entre duas variáveis quantitativas (X, Y).
- **Intervalo:** $r \in [-1, 1]$.
 - $r \approx +1$: associação linear positiva muito forte.
 - $r \approx -1$: associação linear negativa muito forte.
 - $r \approx 0$: ausência de associação *linear* (pode existir relação não linear).

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{cov}(X, Y)}{s_X s_Y}.$$

Coeficiente de correlação amostral de Pearson (r)

- **Propriedades:** adimensional; invariante a transformações lineares de escala
- **Atenção:** muito sensível a outliers; só capta linearidade; $r \approx 0$ não implica independência; não implica causalidade.
- **Boa prática:** inspecione o *scatterplot* antes de interpretar r .

Coeficiente de correlação amostral de Spearman (r_s)

- Mede a **força** e a **direção** da **associação monótona** (crescente/decrescente) entre duas variáveis *quantitativas ou ordinais*.
- Baseia-se nas **posições (ranks)** das observações.
- **Intervalo:** $r_s \in [-1, 1]$.
 - $r_s \approx +1$: monotonia crescente quase perfeita.
 - $r_s \approx -1$: monotonia decrescente quase perfeita.
 - $r_s \approx 0$: ausência de *associação monótona*.

$$r_s = \text{corPearson}(\text{rank}(X), \text{rank}(Y))$$

$$\text{(sem empates)} \quad r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \quad d_i = \text{rank}(x_i) - \text{rank}(y_i).$$

Coeficiente de correlação amostral de Spearman (r_s)

- **Empates:** usa *posições médias*
- **Propriedades:** mais **resistente a outliers** do que Pearson; invariante a transformações **monótonas estritamente crescentes**; adequado para dados ordinais e relações não lineares mas monótonas.
- **Boa prática:** ver *scatterplot* (ou dos *ranks*) antes de interpretar r_s .

Boas práticas e checklist

Transformações e escalas

- Transformações (log, raiz) podem reduzir assimetria/heterocedasticidade.
- Reporte resultados na **escala original** quando necessário para interpretação.
- Eixos e unidades **claros**.

Checklist de EDA

- **Contexto:** dicionário dos dados, unidades, período, fonte.
- **Qualidade:** NA, duplicados, intervalos plausíveis.
- **Univariada:** centro (\tilde{x}/\bar{x}), dispersão (IQR/ s), forma e outliers.
- **Bivariada:** gráficos adequados; correlações; estratificar por grupos relevantes.
- **Documentação:** escolhas (binwidth, método de quantis), critérios de outliers e decisões tomadas.

Referências

- Wickham, H. & Grolemund, G. (2017). *R for Data Science*.
- Devore, J., Berk, K., Carlton, M. (2021). *Modern Mathematical Statistics with Applications*.