Métodos Iterativos para Otimização Sem Restrições

Fernanda Costa

Departamento de Matemática
Universidade do Minho

Outline

1. Métodos iterativos para otimização sem restrições
2. Critério de paragem
3. Métodos de procura unidirecional (geral)
4. Comprimento do passo
5. Convergência dos métodos de procura unidirecional
6. Taxas de convergência
7. Anexo
   - Resolução do exemplo da página 14
   - Demonstração do Teorema (Zoutendijk)

Métodos iterativos para otimização sem restrições

Em geral, não se consegue resolver

$$\underset{w \in \mathbb{R}^d}{\text{minimizar}} \; F(w)$$

analiticamente, e recorre-se a métodos iterativos.

Métodos iterativos para Otimização

- Começam a partir de um dado ponto inicial $w^{(0)} \in \mathbb{R}^d$ (aproximação inicial à solução);
- Dado $w^{(k)}$, calculam um novo ponto (melhor) $w^{(k+1)}$, e este processo repete-se ($k = 0, 1, 2, \ldots$).
- Geram uma sucessão de pontos $w^{(1)}, w^{(2)}, \ldots, w^{(k)}, \ldots$ que converge para a solução ótima w^*.
- O método *termina* quando deixa de ser possível obter progresso significativo ou quando a solução ótima w^* é aproximada com precisão previamente fixada.

Critério de paragem

- Ao utilizar um algoritmo de otimização, procura-se um ponto $w^{(k)}$ onde

$$\nabla F(w^{(k)}) = \mathbf{0}.$$

  Na prática, devido à aritmética de precisão finita, adota-se como critério de paragem

$$\|\nabla F(w^{(k)})\|_\infty < \varepsilon, \tag{1}$$

  com $\varepsilon > 0$ suficientemente pequeno.

- A segunda condição de otimalidade (Hessiana semidefinida positiva) não é, em geral, utilizada.

  Assim, o algoritmo apenas garante um ponto estacionário (ponto máximo, mínimo ou sela).

- Contudo, como os algoritmos que vamos estudar geram direções de descida, espera-se, na prática, convergência para um mínimo local.

- Num algoritmo prático, utilizam-se outras condições para além da condição (1). Por vezes, a função pode apresentar problemas numéricos ou ser ilimitada inferiormente, que impedem a verificação da condição (1).

- Para evitar que o algoritmo execute indefinidamente, é habitual impor um *número máximo* ao *número de iterações*, $Kmax$, ou ao *número de avaliações da função*, $NFmax$, ou ao *tempo de execução*, $Tmax$.

- Além disso, para detetar situações em que o algoritmo não está a fazer progressos significativos, podem definir-se condições adicionais baseadas na proximidade entre dois pontos consecutivos e na variação do valor da função objetivo, em termos absoluto ou relativo:

$$\|w^{(k)} - w^{(k-1)}\| \leq \varepsilon_2 \quad \text{ou} \quad \frac{\left\|w^{(k)} - w^{(k-1)}\right\|_\infty}{\|w^{(k)}\|_\infty} \leq \varepsilon_2$$

$$|F(w^{(k)}) - F(w^{(k-1)})| \quad \text{ou} \quad \frac{\left|F(w^{(k)}) - F(w^{(k-1)})\right|}{|F(w^{(k)})|} \leq \varepsilon_3$$

.

Critérios de paragem em algoritmos para otimização sem restrições.

Critério (proposto por Wolfe). Parar o algoritmo se:

1. $\left\|\nabla F(w^{(k)})\right\|_\infty \leq \varepsilon_1$ e **(medida de estacionaridade)**

2. $\dfrac{\left\|w^{(k)} - w^{(k-1)}\right\|_\infty}{\|w^{(k)}\|_\infty} \leq \varepsilon_2$ e

3. $\dfrac{\left|F(w^{(k)}) - F(w^{(k-1)})\right|}{|F(w^{(k)})|} \leq \varepsilon_3$

onde $\varepsilon_1 > 0, \varepsilon_2 > 0, \varepsilon_3 > 0$ são pequenas tolerâncias próximas de zero. Na prática, $\varepsilon_1 = 10^{-6}$ e $\varepsilon_2 = \varepsilon_3 = 10^{-6}$.

Critério (proposto por Gill e Murray): Terminar o algoritmo se:

1. $\|\nabla F(w^{(k)})\|_\infty \leq \varepsilon^{\frac{1}{3}} \left(1 + |F(w^{(k)})|\right)$ e
2. $\|w^{(k)} - w^{(k-1)}\|_\infty \leq \varepsilon \left(1 + \|w^{(k)}\|_\infty\right)$ e
3. $|F(w^{(k)}) - F(w^{(k-1)})| \leq \varepsilon^2 \left(1 + |F(w^{(k)})|\right)$

onde $\varepsilon > 0$ é uma pequena tolerância próxima de zero.

Observações:

- Este critério é de aplicação mais geral. Pode ser aplicado a problemas em que a solução ótima é o vetor nulo ou o valor ótimo da função objetivo é zero.

Métodos de procura unidirecional (geral)

Os métodos de procura unidirecional tem, em cada iteração, três passos principais:

Estrutura geral

1. Escolher uma direção de procura $s^{(k)}$ a partir do ponto atual $w^{(k)}$;
2. Calcular a distância a percorrer nessa direção, η_k, realizando uma procura unidirecional;
3. Mover para o novo ponto: $w^{(k+1)} = w^{(k)} + \eta_k \, s^{(k)}$.

O bom desempenho de um método de procura unidirecional depende das escolhas da *direção de procura* $s^{(k)}$ e do *comprimento do passo* η_k.

De preferência $s^{(k)}$ é uma *direção de descida*, isto é, $s^{(k)T} \nabla F(w^{(k)}) < 0$, o que garante que a função F decresce ao longo dessa direção.

O *método de procura undirecional (geral)* é definido pelo seguinte algoritmo iterativo.

Algoritmo 1: Método de procura unidirecional (geral)

1. **Entrada**: F, $w^{(0)}$, tolerância $\varepsilon > 0$
2. Fazer $k = 0$
3. **Enquanto** ($\|\nabla F(w^{(k)})\|_\infty > \varepsilon$) **fazer**
4. Calcular uma direção de procura $s^{(k)}$ tal que $s^{(k)\,T}\nabla F(w^{(k)}) < 0$
5. Calcular o comprimento do passo η_k tal que

$$F(w^{(k)} + \eta_k s^{(k)}) < F(w^{(k)})$$

6. Fazer $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$
7. Fazer $k = k + 1$
8. **Fim enquanto**
9. **Saída:** $w^* \leftarrow w^{(k)}$, $F^* \leftarrow F(w^{(k)})$ (solução ótima e valor ótimo)

Existem vários métodos para escolher a *direção de procura* $s^{(k)}$. Na aula seguinte, estudaremos os seguintes:

- Método de descida máxima (ou Método do gradiente).
- Método de Newton.
- Métodos quasi-Newton.

Como escolher o *comprimento do passo* η_k?

- A escolha de η_k deverá conduzir a um decréscimo substancial de F e ser pouco dispendiosa.

Comprimento do passo

A procura exata do η_k:

$$\underset{\eta \in \mathbb{R}_{\mathbf{0}}^{+}}{\text{minimizar}} \ \phi(\eta) = F(w^{(k)} + \eta s^{(k)})$$

é impraticável, devido ao elevado custo computacional e, em geral, não é necessária. Na prática, recorre-se a técnicas de procura não exata.

Vamos tentar decrescer

$$\phi(\eta) = F(w^{(k)} + \eta s^{(k)}), \quad \eta \geq 0$$

a partir de $\eta = 0$.

Contudo, minimizar $\phi(\eta)$ pode ser difícil.

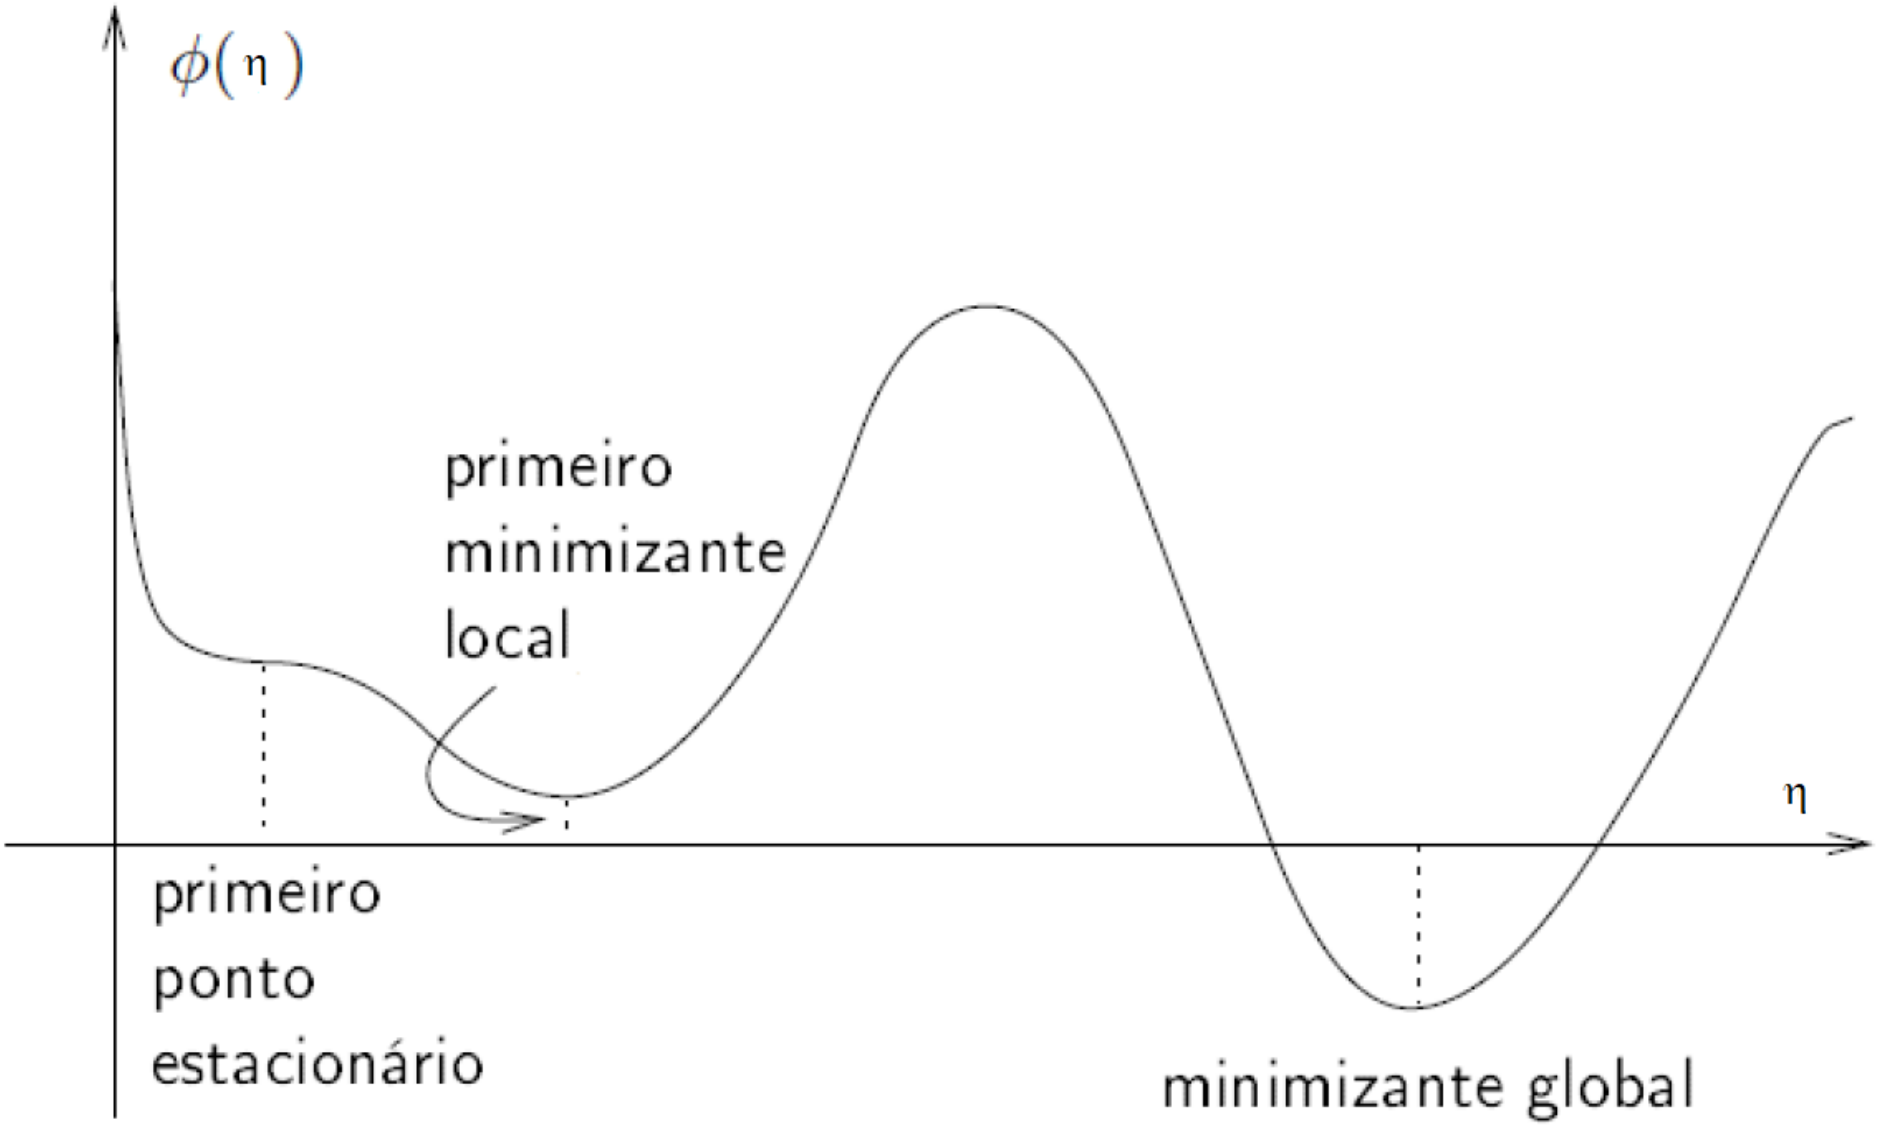
$\phi(\eta)$
primeiro
minimizante
local
η
primeiro
ponto
estacionário
minimizante global

Pretende-se testar um número finito (pequeno) de valores para η, por ex.,

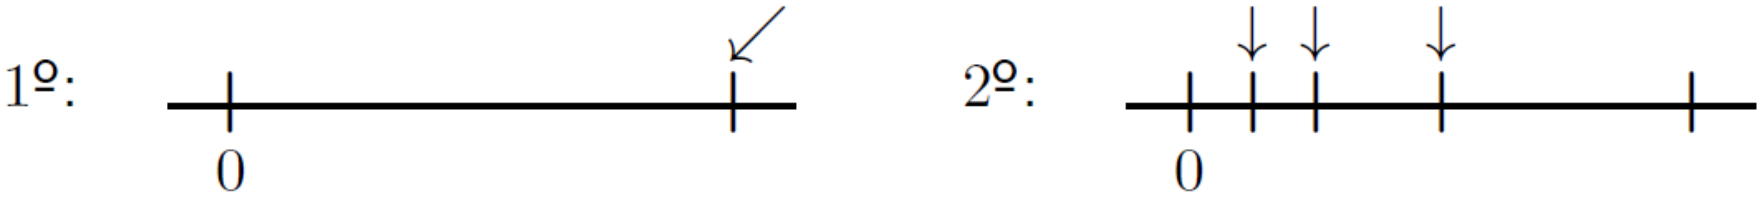

Uma condição natural a impor ao parâmetro η_k é a **condição de decréscimo simples**:

$$F\left(w^{(k)} + \eta_k s^{(k)}\right) < F\left(w^{(k)}\right).$$

Mas, esta condição, por si só, não garante a convergência para um ponto estacionário, podendo o método convergir antes de o atingir!

Exemplo: Considere $F : \mathbb{R} \to \mathbb{R}$ dada por $F(w) = w^2$, que tem um minimizante global em $w^* = 0$. (a) Utilize o algoritmo de descida geral com $s^{(k)} = -1$, $\eta_k = \frac{1}{2^{k+1}}$ e ponto inicial dado por $w^{(0)} = 2$. Desenhe os iterados gerados pelo algoritmo, definidos por $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)}$, usando o MatLab. O que pode concluir? (b) Resolva a alínea anterior com com $s^{(k)} = (-1)^{k+1}$ e $\eta_k = 2 + \frac{3}{2^{k+1}}$.

Solução:

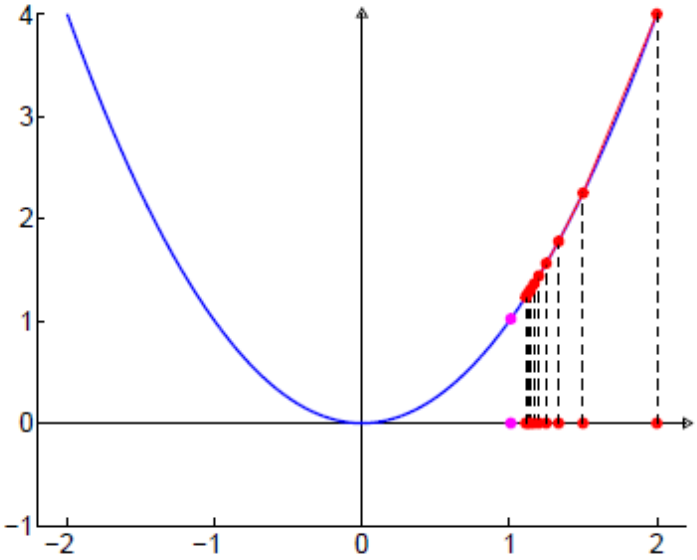

(a) passos muito curtos
$w^{(k)} = 1 + \frac{1}{2^k}$
$w^{(k)} \to 1$
1 não é minimizante de F

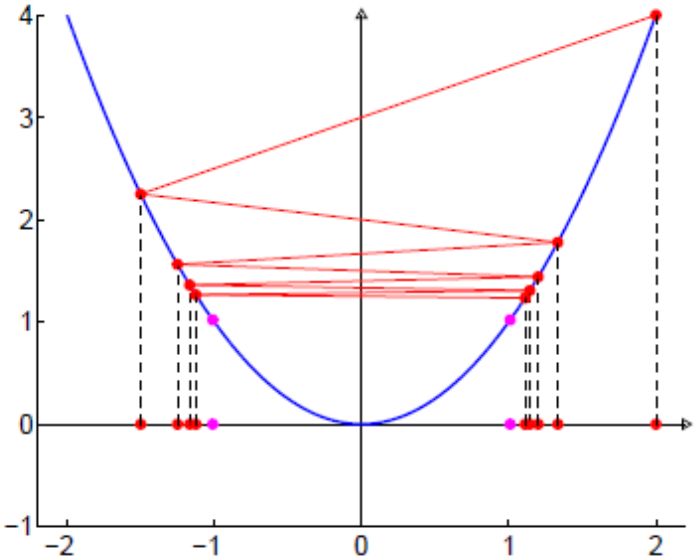

(b) passos muito longos
$w^{(k)} = 1 + \frac{1}{2^k}$ (k ímpar); $w^{(k)} = -1 - \frac{1}{2^k}$ (k par)
$w^{(k)} \to -1$ (k par)
$w^{(k)} \to 1$ (k ímpar)
-1 e 1 não são minimizantes de F

Em ambos os casos, o algoritmo satisfaz a condição de decréscimo simples, $(F(w^{(k+1)}) < F(w^{(k)})$ para $k = 0, 1, \ldots)$, mas não converge para o minimizante!

Para simplificar a exposição da procura undirecional, vamos considerar a função de 1 variável

$$\phi(\eta) = F(w^{(k)} + \eta s^{(k)}) \tag{2}$$

onde $\eta = 0$ corresponde ao início da procura undirecional ($w^{(k)}$), e portanto $\phi(0) = F(w^{(k)})$.

Pela regra da cadeia, usando $w = w^{(k)} + \eta s^{(k)}$, a derivada de ϕ é

$$\phi'(\eta) = \frac{\partial(F(w))}{\partial \eta} = \sum_{i=1}^{d} \frac{\partial F}{\partial w_i} \frac{dw_i}{d\eta} \Longleftrightarrow$$

$$\phi'(\eta) = \nabla F(w^{(k)} + \eta s^{(k)})^T s^{(k)}$$

que é a derivada direcional de F ao longo da direção de procura $s^{(k)}$. O declive no início de cada procura unidirecional é

$$\phi'(0) = \nabla F(w^{(k)})^T s^{(k)}.$$

Como $s^{(k)}$ tem de ser uma direção de descida, $\phi'(0) < 0$ é sempre negativo!

Condições de Wolfe

As condições de Wolfe englobam a **condição de decréscimo suficiente** (CDS) e a **condição de curvatura** (CC).

A CDS, também designada por **condição de Armijo**, é dada pela desigualdade:

$$F(w^{(k)} + \eta s^{(k)}) - F(w^{(k)}) \leq c_1 \eta \underbrace{\nabla F(w^{(k)})^T s^{(k)}}_{\phi'(0)} \Longleftrightarrow$$

$$\underbrace{F(w^{(k)} + \eta s^{(k)})}_{\phi(\eta)} \leq \underbrace{F(w^{(k)}) + c_1 \eta \nabla F(w^{(k)})^T s^{(k)}}_{l(\eta)} \tag{3}$$

onde $0 < c_1 < 1$ é uma constante. A quantidade $\eta\phi'(0)$ representa o decréscimo esperado da função F. O multiplicador c_1 diz que (3) será satisfeita desde que se obtenha pelo menos uma pequena fração do decréscimo esperado.

Em (3), $l(\eta)$ é uma função linear de declive negativo $c_1\eta\phi'(0)$. Como $c_1 \in (0, 1)$, a reta $l(\eta)$ situa-se acima do gráfico de $\phi(\eta)$ para valores de η pequenos.

A CDS diz que η é aceitável se $\phi(\eta) \leq l(\eta)$. Os intervalos onde CDS é satisfeita são apresentados na Figura. Na prática, c_1 é escolhido bastante pequeno, $c_1 = 10^{-4}$.

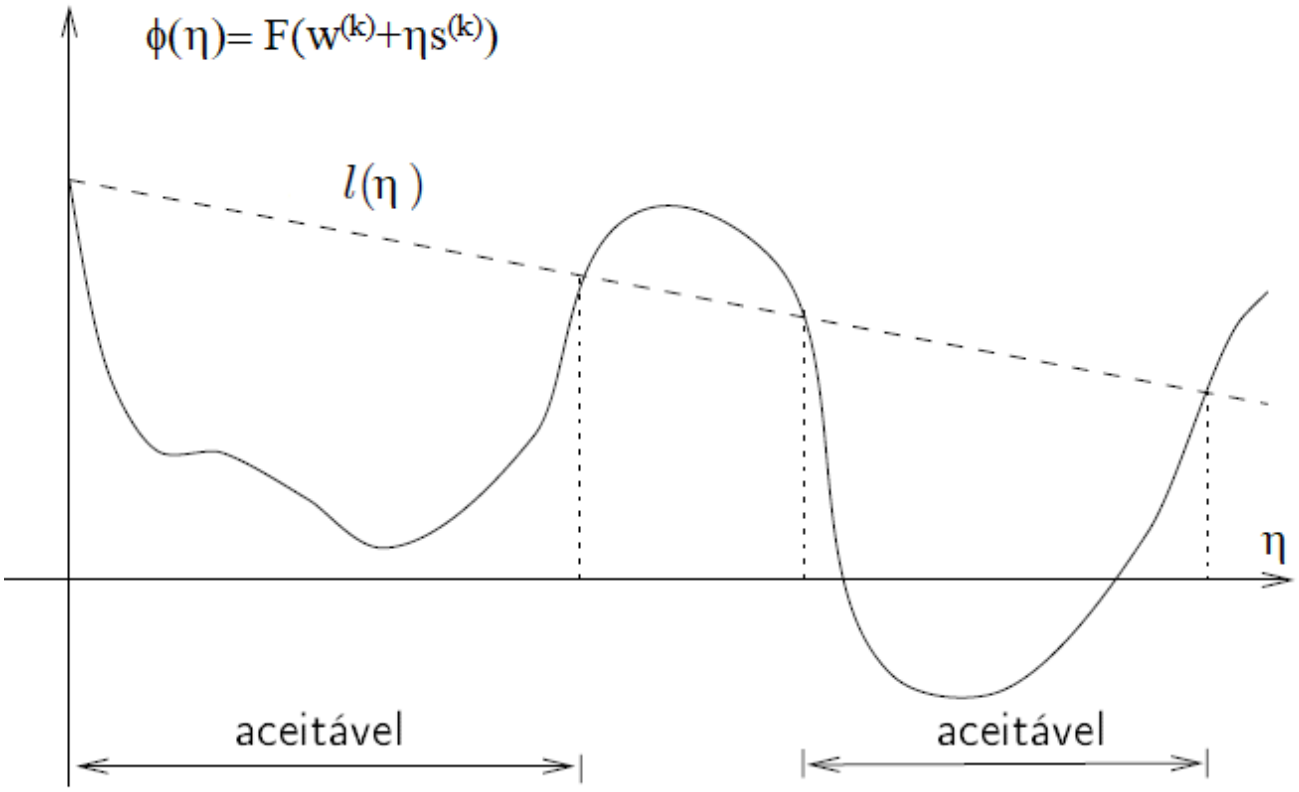

Condição de decréscimo suficiente

A CDS, por si só, não é suficiente para garantir que o algoritmo faça um progresso razoável porque, como podemos ver da Figura, pode ser satisfeita por comprimentos de passo muito pequenos!

Para excluir passos demasiado curtos, introduz-se uma segunda condição, a CC, que exige que η_k satisfaça:

$$\underbrace{\nabla F(w^{(k)} + \eta_k s^{(k)})^T s^{(k)}}_{\phi'(\eta_k)} \geq c_2 \underbrace{\nabla F^T(w^{(k)}) s^{(k)}}_{\phi'(0)} \tag{4}$$

com $c_2 \in (c_1, 1)$, onde c_1 é a constante de (3).

A CC rejecta declives demasiados negativos (o declive em η_k, $\phi'(\eta_k)$, tem de ser maior c_2 vezes o declive inicial $\phi'(0)$). Isto faz sentido porque, se o declive $\phi'(\eta)$ é fortemente negativo, isso indica que ainda é possível reduzir significativamente o valor de F avançando mais na direção $s^{(k)}$.

Por outro lado, se $\phi'(\eta)$ for apenas ligeiramente negativo, ou mesmo positivo, isso indica que não é razoável esperar uma redução muito maior nessa direção. Portanto, faz sentido terminar a procura.

Na prática, $c_2 = 0.9$ quando a direção de procura $s^{(k)}$ é dada pelo método de Newton ou pelo método quasi-Newton.

Os intervalos onde CC é satisfeita são apresentados na Figura.

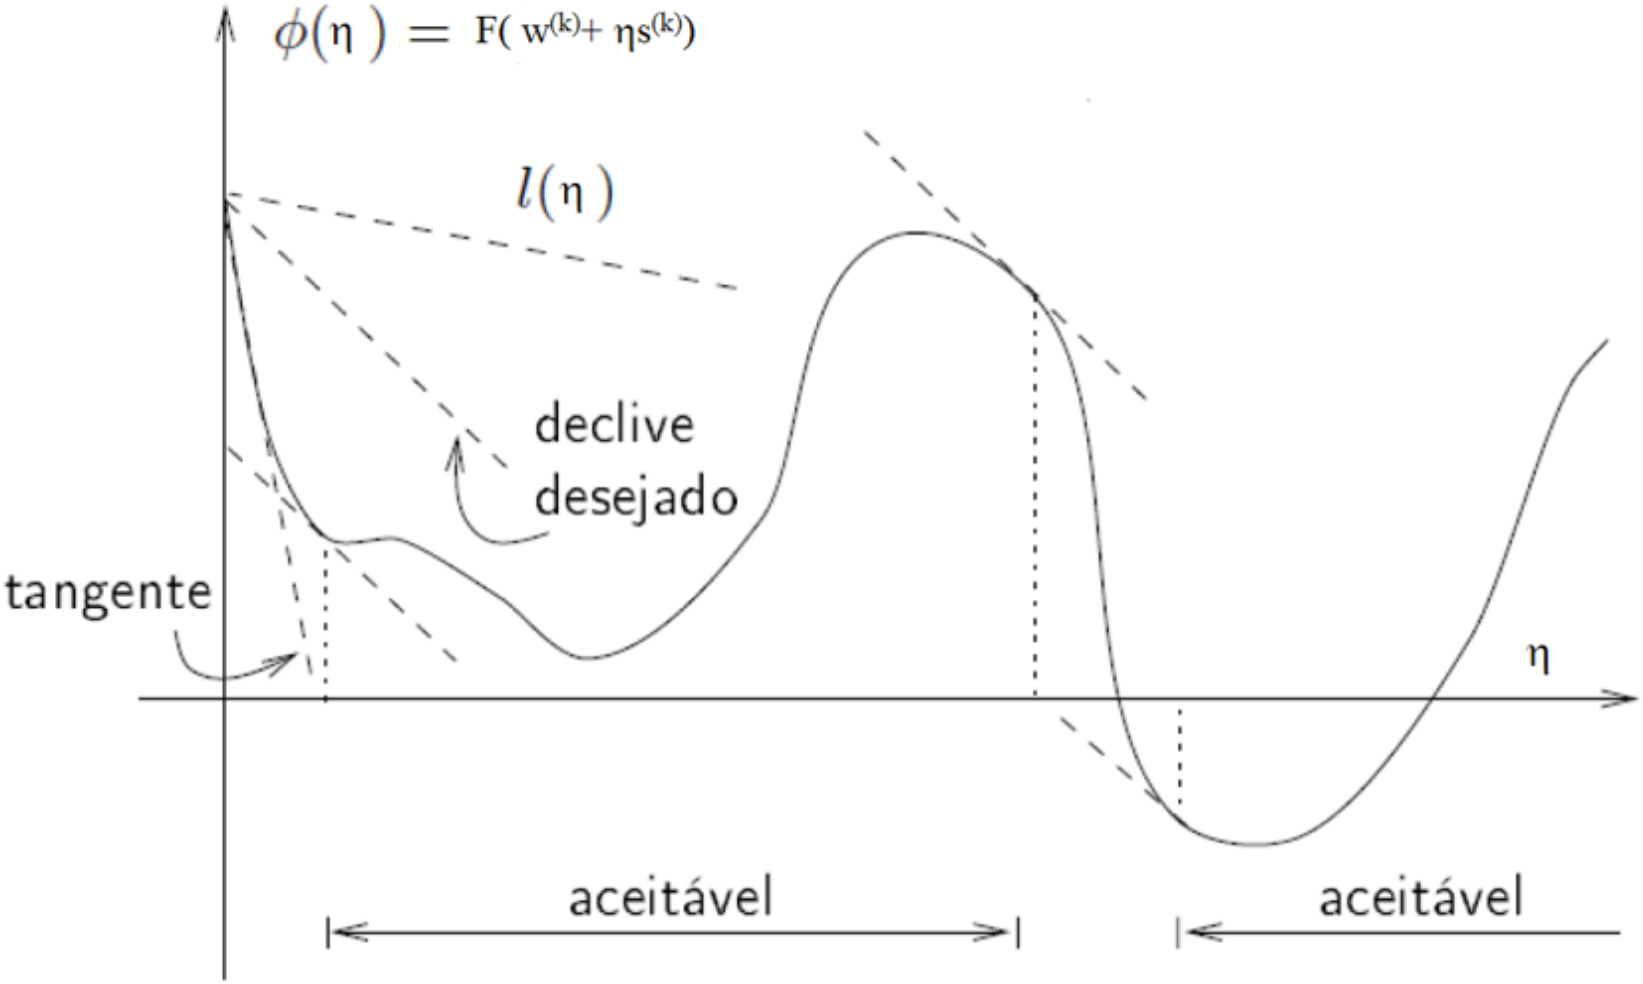

Condição de curvatura

Lema

Seja $F : \mathbb{R}^d \to \mathbb{R}$ continuamente diferenciável. Seja $s^{(k)}$ uma direcção de descida em $w^{(k)}$ e F limitada inferiormente ao longo da semi-recta $\{w^{(k)} + \eta s^{(k)} : \eta > 0\}$. Então, se $0 < c_1 < c_2 < 1$, existem intervalos de comprimentos de passo satisfazendo as condições de Wolfe, CDS (3) e CC (4).

Demonstração: $\phi(\eta) = F(w^{(k)} + \eta s^{(k)})$ é limitada inferiormente.
Uma vez que $0 < c_1 < 1$, $l(\eta) = F(w^{(k)}) + c_1 \eta \nabla F(w^{(k)})^T s^{(k)}$ tende para $-\infty$ quando $\eta \to +\infty$.
Por isso intersecta ϕ pelo menos uma vez.
Seja η' o menor valor de η dessa intersecção, assim

$$F(w^{(k)} + \eta' s^{(k)}) = F(w^{(k)}) + c_1 \eta' \nabla F(w^{(k)})^T s^{(k)}$$

Logo a CDS é válida $\forall \eta < \eta'$.
Pelo teorema do valor médio

$$\exists \eta'' \in (0, \eta') : F(w^{(k)} + \eta' s^{(k)}) - F(w^{(k)}) = \eta' \nabla F(w^{(k)} + \eta'' s^{(k)})^T s^{(k)}$$

Tendo em conta as duas últimas equações, vem

$$\nabla F(w^{(k)} + \eta'' s^{(k)})^T s^{(k)} = c_1 \nabla F(w^{(k)})^T s^{(k)}$$

Uma vez que $c_1 < c_2$ e $\nabla F(w^{(k)})^T s^{(k)} < 0$, vem

$$\nabla F(w^{(k)} + \eta'' s^{(k)})^T s^{(k)} = c_1 \nabla F(w^{(k)})^T s^{(k)} > c_2 \nabla F(w^{(k)})^T s^{(k)}$$

Assim, η'' satisfaz as condições de Wolfe e pelo facto de ∇F ser contínuo, existe um intervalo em torno de η'' onde as condições de Wolfe são satisfeitas. $\square$

Os intervalos onde as condições de Wolfe, CDS e CC, são satisfeitas são apresentados na Figura.

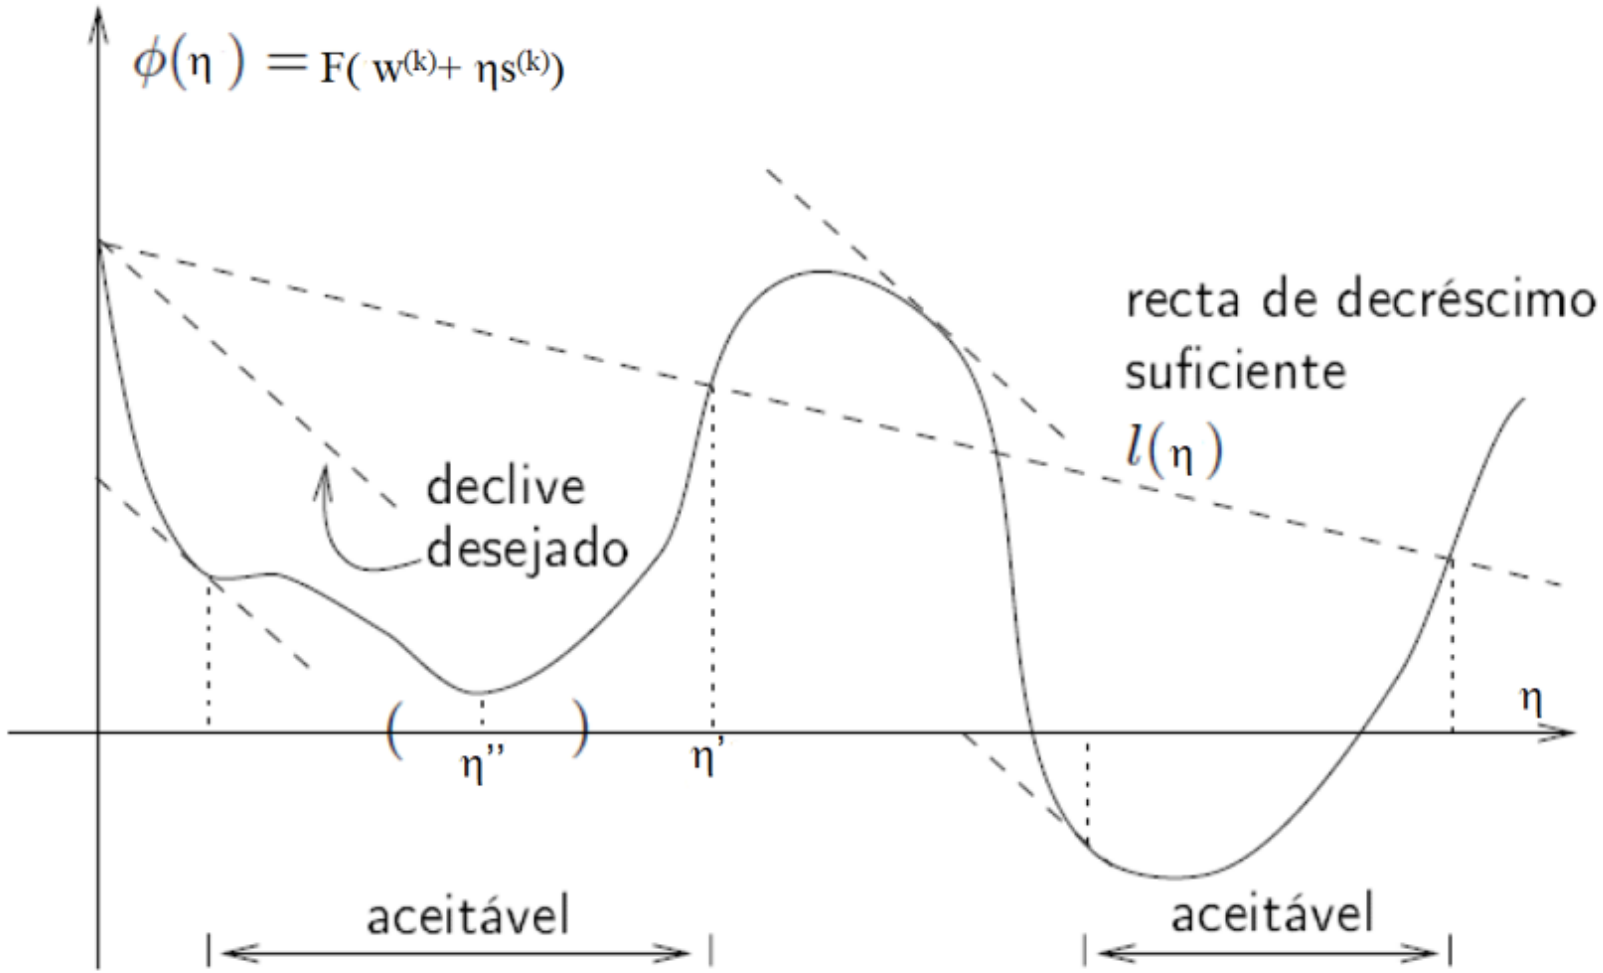

Intervalos de comprimentos de passo satisfazendo as condições de Wolfe

Decréscimo Suficiente e Backtracking

Como referido a CDS (3), por si só, não garante progresso adequado ao longo da direção de procura.

Contudo, se o algoritmo de procura unidirecional selecionar os comprimentos de passo candidatos de forma apropriada, recorrendo à estratégia de **backtracking**, podemos dispensar a CC (4) e usar apenas a CDS (3).

Algoritmo: Condição de Armijo com backtracking

---

1. **Entrada:** $\eta_0 > 0$, $\rho \in (0,1)$, $c \in (0,1)$, F, $\nabla F(w^{(k)})$, $w^{(k)}$, $s^{(k)}$
2. Fazer $\eta = \eta_0$
3. **Enquanto** $F(w^{(k)} + \eta s^{(k)}) > F(w^{(k)}) + c\eta \nabla F(w^{(k)})^T s^{(k)}$ **fazer**
4. Fazer $\eta = \rho\,\eta$
5. **Fim enquanto**
6. **Saída:** $\eta_k \leftarrow \eta$ (valor para η_k)

Notas (estratégia de *backtracking*):

- Inicia-se com um comprimento de passo relativamente grande e este é sucessivamente reduzido, multiplicando por um fator $\rho < 1$, até que a CDS seja satisfeita.
- Trata-se de uma heurística simples para garantir a verificação da CDS.
- Na prática, o comprimento de passo inicial é frequentemente escolhido como $\eta_0 = 1$ quando a direção de procura $s^{(k)}$ é obtida pelo método de Newton ou por métodos quasi-Newton. Noutros métodos, como o método do gradiente, podem ser usados outros valores iniciais.
- O procedimento termina sempre, pois a CDS é satisfeita para η_k suficientemente pequeno.
- Na prática, o fator de contração é geralmente fixo, sendo habitual a escolha $\rho = \frac{1}{2}$.

Convergência dos métodos de procura unidirecional

- Diz-se que um método tem *convergência de primeira ordem* se a sucessão de iterados $\{w^{(k)}\}$ gerada pelo método converge para um *ponto estacionário*.
  - Usa-se o termo *convergência global* se o método converge para um ponto estacionário qualquer que seja o ponto inicial $w^{(0)}$.
  - Usa-se o termo *convergência local* se o método converge para um ponto estacionário apenas se o ponto inicial $w^{(0)}$ está suficientemente próximo de uma solução w^*.

Convergência dos métodos de procura unidirecional

- Para garantir convergência global, é necessário escolher bem tanto os comprimentos de passo η_k quanto as direções de procura $s^{(k)}$.

- Apresentamos um teorema que estabelece condições sobre a direção de procura $s^{(k)}$ para garantir convergência global, baseado no ângulo θ_k entre $s^{(k)}$ e a direção de máxima descida $-\nabla F(w^{(k)})$:

$$\cos\theta_k = \frac{-\nabla F(w^{(k)})^\top s^{(k)}}{\|\nabla F(w^{(k)})\| \, \|s^{(k)}\|} \tag{5}$$

  e assumindo que η_k satisfaz as condições de Wolfe.

- Este Teorema é importante: por exemplo, mostra que o método da descida máxima (método do gradiente) é *globalmente convergente*; para outros métodos, descreve até que ponto $s^{(k)}$ pode desviar-se da direção de máxima $-\nabla f(w^{(k)})$ e ainda assim gerar um algoritmo *globalmente convergente*.

Teorema (Zoutendijk)

Considere-se um método iterativo $w^{(k+1)} = w^{(k)} + \eta s^{(k)}$, *em que* $s^{(k)}$ *é uma direção de descida e* η_k *satisfaz as condições de Wolfe.*
Suponhamos que F *é limitada inferiormente em* $\mathbb{R}^d$ *e que é continuamente diferenciável num conjunto aberto* $\mathcal{N}$ *contendo o conjunto de nível*

$$\mathcal{L}(w^{(0)}) = \{\, w : F(w) \leq F(w^{(0)}) \,\},$$

onde $w^{(0)}$ *é o ponto inicial da iteração.*
Suponhamos, ainda, que ∇F *é contínua à Lipschitz (com constante* $L > 0$*) em* $\mathcal{N}$*:*

$$\left\|\nabla F(w) - \nabla F(\tilde{w})\right\| \leq L\left\|w - \tilde{w}\right\|.$$

Então, tem-se

$$\sum_{k=0}^{+\infty} \cos^2\theta_k \, \|\nabla F(w^{(k)})\|^2 < +\infty \qquad \textit{(condição de Zoutendijk).}$$

Do teorema de Zoutendijk, resulta que

$$\cos^2 \theta_k \, \|\nabla F(w^{(k)})\|^2 \longrightarrow 0.$$

Se existir uma constante $\varepsilon > 0$ tal que

$$\cos \theta_k \geq \varepsilon > 0 \quad \text{para todo } k,$$

então

$$\cos^2 \theta_k \, \|\nabla F(w^{(k)})\|^2 \longrightarrow 0 \quad \Longleftrightarrow \quad \|\nabla F(w^{(k)})\| \longrightarrow 0.$$

Por outras palavras, podemos garantir que as normas do gradiente $\|\nabla F(w^{(k)})\|$ convergem para zero, desde que as direções de procura $s^{(k)}$ nunca se tornem quase ortogonais ao vetor gradiente $\nabla F(w^{(k)})$.

Exemplos:

- **Método de descida máxima:**

$$s^{(k)} = -\nabla f(w^{(k)}) \;\Rightarrow\; \cos\theta_k = 1 > 0 \quad \forall k \;\Rightarrow\; \text{convergência global.}$$

  Método simples e intuitivo, mas pode ser lento.

- **Métodos do tipo Newton:**

$$s^{(k)} = -B_k^{-1}\nabla f(w^{(k)}),$$

  com B_k uma matriz simétrica e definida positiva (SPD) e com número de condição limitado, $cond(B_k) = \|B_k\|\,\|B_k^{-1}\| \leq M$, então:

$$\cos\theta_k \geq \frac{1}{M} > 0 \quad \forall k \;\Rightarrow\; \text{convergência global.}$$

  Se B_k são definidas positivas, com número de condição limitado, e η_k satisfaz as condições de Wolfe, então o método é *globalmente convergente*.

  Isto inclui, o método de descida máxima, alguns métodos de Newton e quasi-Newton.

Taxas de Convergência

Uma das principais medidas de desempenho de um algoritmo de otimização é sua *taxa (velocidade) de convergência*.

Definição (Convergência linear)

Seja $\{w^{(k)}\}$ *uma sucessão em* $\mathbb{R}^d$ *convergente para* w^*. *Diz-se que a sucessão* $\{w^{(k)}\}$ *converge linearmente para* w^* *se existir uma constante* $r \in]0,1[$ *tal que*

$$\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|} = r. \tag{6}$$

- Isto significa que a distância à solução w^* diminui a cada iteração por, pelo menos, a um fator constante r estritamente menor que 1.
- O número r é chamado de taxa de convergência.

Exemplo: Seja $w^{(k)} = 1 + \frac{1}{2^k}$.
A sucessão $\{w^{(k)}\}$ converge para $w^* = 1$: $\lim_{k\to\infty} w^{(k)} = \lim_{k\to\infty} 1 + \frac{1}{2^k} = 1 + 0 = 1$.
Esta convergência é linear, com taxa de convergência $r = 0.5$, pois

$$\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|} = \lim_{k\to\infty} \frac{1 + \frac{1}{2^{k+1}} - 1}{1 + \frac{1}{2^k} - 1} = \frac{1}{2} \in]0,1[.$$

Vejamos agora uma forma mais rápida de convergência.

Definição (Convergência super-linear)

Seja $\{w^{(k)}\}$ uma sucessão em $\mathbb{R}^d$ convergente para w^*. Diz-se que a sucessão $\{w^{(k)}\}$ converge superlinearmente para w^* se

$$\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|} = 0$$

(taxa de convergência $r = 0$).

Em oposição, vejamos agora uma forma menos rápida de convergência.

Definição 1 (Convergência sub-linear)

Seja $\{w^{(k)}\}$ uma sucessão em $\mathbb{R}^d$ convergente para w^*. Diz-se que a sucessão $\{w^{(k)}\}$ *converge sublinearmente* para w^* se

$$\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|} = 1$$

(taxa de convergência $r = 1$).

Exemplo:

Seja $w^{(k)} = \dfrac{1}{k!}$.

A sucessão $\{w^{(k)}\}$ converge para $w^* = 0$: $\lim\limits_{k\to\infty} w^{(k)} = \lim\limits_{k\to\infty} \dfrac{1}{k!} = 0$.

Esta convergência é super-linear pois

$$\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|} = \lim_{k\to\infty} \frac{\frac{1}{(k+1)!} - 0}{\frac{1}{k!} - 0} = \lim_{k\to\infty} \frac{1}{k+1} = 0.$$

Exemplo:

Seja $w^{(k)} = \dfrac{1}{k}$.

A sucessão $\{w^{(k)}\}$ converge para $w^* = 0$: $\lim\limits_{k\to\infty} w^{(k)} = \lim\limits_{k\to\infty} \dfrac{1}{k} = 0$.

Esta convergência é sub-linear pois

$$\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|} = \lim_{k\to\infty} \frac{\frac{1}{k+1} - 0}{\frac{1}{k} - 0} = \lim_{k\to\infty} \frac{k}{k+1} = 1.$$

Outras formas de convergência, ainda mais rápidas, são as *taxas de convergências supra-lineares*.

A definição seguinte distingue estas taxas de convergências.

Definição (Convergência de ordem q)

Seja $\{w^{(k)}\}$ uma sucessão em $\mathbb{R}^d$ convergente para w^*. Diz-se que a sucessão $\{w^{(k)}\}$ converge com ordem q, $q > 1$ para w^* se existir uma constante $r > 0$ tal que

$$\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|^2} = r$$

Em particular,

- *a convergência de ordem $q = 2$ é chamada de convergência quadrática;*
- *a convergência de ordem $q = 3$ é chamada de convergência cúbica.*

Síntese:

- A velocidade de convergência de uma sucessão é tanto maior quanto maior for a ordem de convergência q;
- e para uma mesma ordem de convergência q, a velocidade de convergência é tanto maior quanto menor for a taxa de convergência r.

Exemplo:
Seja $w^{(k)} = 10^{-2^k}$. A sucessão $\{w^{(k)}\}$ *converge quadraticamente* para $w^* = 0$.
Vejamos:

$\lim_{k\to\infty} w^{(k)} = \lim_{k\to\infty} 10^{-2^k} = \lim_{k\to\infty} 10^{-\infty} = 0$, e portanto, $\{w^{(k)}\}$ converge para $w^* = 0$.

Esta convergência é quadrática pois

$$\begin{aligned}
\lim_{k\to\infty} \frac{\|w^{(k+1)} - w^*\|}{\|w^{(k)} - w^*\|^2} &= \lim_{k\to\infty} \frac{10^{-2^{k+1}}}{\left(10^{-2^k}\right)^2} \\
&= \lim_{k\to\infty} \frac{10^{-2^{k+1}}}{10^{-2\cdot 2^k}} \\
&= \lim_{k\to\infty} \frac{10^{-2^{k+1}}}{10^{-2^{k+1}}} \\
&= 1.
\end{aligned}$$

Notas: (sobre taxas de convergência)

- A *convergência quadrática* é uma característica muito desejável num algoritmo iterativo.
- Na prática, ordens de convergência superiores a $q = 2$ geralmente não compensam serem consideradas.
- Qualquer sucessão que *converge quadraticamente*, também *converge superlinearmente*.
- Qualquer sucessão que *converge superlinearmente*, também *converge linearmente*.
- Qualquer sucessão que *converge linearmente*, também *converge sublinearmente*.

Resolução matemática do exemplo da página 14:

(a): Matematicamente temos $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)} = w^{(k)} - \eta_k$, para $k = 0, 1, 2, \ldots$:

$$\begin{aligned} w^{(1)} &= w^{(0)} - \eta_0 \\ w^{(2)} &= w^{(1)} - \eta_1 = w^{(0)} - \eta_0 - \eta_1 \\ \ldots &= \ldots \end{aligned}$$

$$w^{(k+1)} = w^{(k)} - \eta_k = w^{(0)} - \sum_{i=0}^{k} \eta_i .$$

Portanto,

$$\begin{aligned} w^{(k+1)} &= 2 - \sum_{i=0}^{k} \frac{1}{2^{i+1}} = 2 - \frac{1}{2} \sum_{i=0}^{k} \frac{1}{2^i} = 2 - \frac{1}{2} \left(\frac{1 - \left(\frac{1}{2}\right)^{k+1}}{1 - \frac{1}{2}} \right) = 2 - \left(1 - \left(\frac{1}{2} \right)^{k+1} \right) \\ &= 1 + \left(\frac{1}{2} \right)^{k+1} \end{aligned}$$

Observar que $0 < w^{(k+1)} < w^{(k)}$ e F é crescente para $w > 0$. Portanto, é verificada a condição de decréscimo simples:

$$F\left(w^{(k+1)}\right) < F\left(w^{(k)}\right), \quad \text{para } k = 0, 1, \ldots .$$

Temos, para $k \to \infty$, $w^{(k)} = 1 + \left(\frac{1}{2}\right)^k \to 1$ e $F(w^{(k)}) \to 1$. Mas o minimizante é 0, portanto o 1 não é ponto estacionário.

(b): Matematicamente temos $w^{(k+1)} = w^{(k)} + \eta_k s^{(k)} = w^{(k)} + (-1)^{k+1}\eta_k$, para $k = 0, 1, 2, \ldots$:

$$
\begin{aligned}
w^{(1)} &= w^{(0)} - \eta_0 \\
w^{(2)} &= w^{(1)} + \eta_1 = w^{(0)} - \eta_0 + \eta_1 \\
\ldots &= \ldots
\end{aligned}
$$

$$w^{(k+1)} = w^{(k)} + (-1)^{k+1}\eta_k = w^{(0)} + \sum_{i=0}^{k}(-1)^{i+1}\eta_i.$$

Portanto,

$$
\begin{aligned}
w^{(k+1)} &= 2 + \sum_{i=0}^{k}(-1)^{i+1}(2 + \frac{3}{2^{i+1}}) = 2 + 2\sum_{i=0}^{k}(-1)^{i+1} + 3\sum_{i=0}^{k}\left(\frac{-1}{2}\right)^{i+1} \\
&= 2 + 2\begin{cases} -1, & k \text{ par} \\ 0, & k \text{ ímpar} \end{cases} + 3\left(-\frac{1}{2}\frac{1-(-\frac{1}{2})^{k+1}}{1+\frac{1}{2}}\right) \\
&= 2 + \begin{cases} -2, & k \text{ par} \\ 0, & k \text{ ímpar} \end{cases} + 3\left(-\frac{1}{3}\left(1 - \left(-\frac{1}{2}\right)^{k+1}\right)\right) \\
&= 2 + \begin{cases} -2, & k \text{ par} \\ 0, & k \text{ ímpar} \end{cases} + \left(-1 + \left(-\frac{1}{2}\right)^{k+1}\right) \\
&= 2 + \begin{cases} -3 - \left(\frac{1}{2}\right)^{k+1}, & k \text{ par}, \\ -1 + \left(\frac{1}{2}\right)^{k+1}, & k \text{ ímpar}. \end{cases} = \begin{cases} -1 - \left(\frac{1}{2}\right)^{k+1}, & k \text{ par}, \\ 1 + \left(\frac{1}{2}\right)^{k+1}, & k \text{ ímpar}. \end{cases}
\end{aligned}
$$

Portanto temos, para $k \to \infty$, $w^{(k)} \to -1$ se k par; $w^{(k)} \to 1$ se k ímpar. E $F(w^{(k)}) \to 1$, mas o minimizante é 0, portanto o 1 e -1 não são pontos estacionários.

Demonstração do Teorema (Zoutendijk):

Pela condição de decréscimo suficiente (CDS), tem-se

$$F\left(w^{(k+1)}\right) \leq F\left(w^{(k)}\right) + c_1 \eta_k \nabla F\left(w^{(k)}\right)^\top s^{(k)}.$$

Necessitamos de um limite inferior para η_k. Pela condição de curvatura (CC),

$$\nabla F\left(w^{(k+1)}\right)^\top s^{(k)} \geq c_2 \nabla F\left(w^{(k)}\right)^\top s^{(k)}.$$

Logo, subtraindo $\nabla F\left(w^{(k)}\right)^\top s^{(k)}$ a ambos os membros,

$$\left(\nabla F\left(w^{(k+1)}\right) - \nabla F\left(w^{(k)}\right)\right)^\top s^{(k)} \geq (c_2 - 1) \nabla F\left(w^{(k)}\right)^\top s^{(k)}.$$

Como ∇F é Lipschitz contínua com constante L, obtemos

$$\left\| \left(\nabla F\left(w^{(k+1)}\right) - \nabla F\left(w^{(k)}\right)\right)^\top s^{(k)} \right\| \leq L \eta_k \|s^{(k)}\|^2.$$

Assim,

$$(c_2 - 1) \nabla F\left(w^{(k)}\right)^\top s^{(k)} \leq L \eta_k \|s^{(k)}\|^2,$$

ou, equivalentemente,

$$\eta_k \geq \frac{c_2 - 1}{L} \frac{\nabla F\left(w^{(k)}\right)^\top s^{(k)}}{\|s^{(k)}\|^2}.$$

Temos, pela CDS,

$$F\left(w^{(k+1)}\right) \leq F\left(w^{(k)}\right) + c_1 \eta_k \nabla F\left(w^{(k)}\right)^\top s^{(k)},$$

e, substituindo este limite em CDS, obtemos

$$F\left(w^{(k+1)}\right) \leq F\left(w^{(k)}\right) - c_1 \frac{1-c_2}{L} \frac{\left(\nabla F\left(w^{(k)}\right)^\top s^{(k)}\right)^2}{\|s^{(k)}\|^2}.$$

Definindo

$$c = c_1 \frac{1-c_2}{L} > 0,$$

e usando a relação com o ângulo θ_k entre $s^{(k)}$ e $-\nabla F(w^{(k)})$:

$$\cos\theta_k = \frac{-\nabla F(w^{(k)})^\top s^{(k)}}{\|\nabla F(w^{(k)})\| \, \|s^{(k)}\|} \Longrightarrow -\nabla F(w^{(k)})^\top s^{(k)} = \cos\theta_k \, \|\nabla F(w^{(k)})\| \, \|s^{(k)}\|$$

obtemos

$$F\left(w^{(k+1)}\right) \leq F\left(w^{(k)}\right) - c \cos^2\theta_k \, \|\nabla F(w^{(k)})\|^2.$$

Esta desigualdade mostra que a função decresce pelo menos proporcional a $\cos^2\theta_k \, \|\nabla f(w^{(k)})\|^2$ em cada iteração, o que será fundamental para concluir a convergência da soma usada no teorema de Zoutendijk.

Somando a desigualdade de decrescimento obtida sobre as iterações, temos

$$F\left(w^{(k+1)}\right) \leq F(w^{(0)}) - c \sum_{j=0}^{k} \cos^2 \theta_j \, \|\nabla F(w^{(j)})\|^2.$$

Como F é limitada inferiormente em $\mathcal{L}(w^{(0)})$, seja F^* um tal limite inferior. Então,

$$c \sum_{j=0}^{k} \cos^2 \theta_j \, \|\nabla f(w^{(j)})\|^2 \leq F(w^{(0)}) - F\left(w^{(k+1)}\right) \leq F(w^{(0)}) - F^*.$$

Portanto, a sucessão

$$\left\{ \sum_{j=0}^{k} \cos^2 \theta_j \, \|\nabla F(w^{(j)})\|^2 \right\}$$

é crescente e limitada superiormente, e, portanto é convergente.

Então, considerando $k \to \infty$, obtém-se o resultado do teorema de Zoutendijk:

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \, \|\nabla F(w^{(k)})\|^2 < +\infty \qquad \text{(série convergente).} \qquad \square$$