

# Métodos de Descida Acelerada

Fernanda Costa

Departamento de Matemática  
Universidade do Minho

- 1 Métodos de descida acelerada
  - Heavy-ball Method
  - Nesterov's Accelerated Gradient Method

## Limitações do Método de Descida Máxima (MDM):

- Em cada iteração, o MDM avança na direção do **gradiente negativo**

$$s^{(k)} = -\nabla F(w^{(k)}),$$

que é ortogonal à curva de nível de  $F$  no ponto atual  $w^{(k)}$ .

- Esta direção de procura pode variar significativamente entre iterações.
- Em particular, quando as curvas de nível são estreitas e alongadas:
  - as direções sucessivas podem ser quase opostas entre si e podem ser quase ortogonais à direção em que se encontra o minimizante;
  - o método pode dar passos pequenos, conduzindo a **convergência lenta**.

- O MDM é **greedy** (“ganancioso”) pois avança na direção aparentemente mais produtiva no ponto atual  $w^{(k)}$ , ignorando a informação obtida sobre a função  $F$  nas iterações anteriores.
- Neste capítulo, apresentamos métodos que **incorporam informação** sobre a função e a exploram esse conhecimento na escolha das direções de procura  $s^{(k)}$  e dos comprimentos de passo  $\eta_k$ .

- Uma classe de métodos recorre ao ***momentum***, em que a direção de procura é semelhante à utilizada no passo anterior, mas adiciona uma pequena componente de  $-\nabla F$  avaliado no ponto atual (ou num ponto próximo).
- Cada direção de procura é, portanto, uma combinação de todos os gradientes anteriores (“memória do processo”), constituindo uma codificação compacta do histórico da pesquisa.
- Exemplos de métodos com ***momentum***:
  - ▶ **Heavy-ball method** (método da bola pesada);
  - ▶ **Nesterov’s accelerated gradient method** (métodos de gradiente acelerado de Nesterov).

# Métodos do Gradiente com *momentum*

Os métodos de gradiente com *momentum* são procedimentos em que cada passo é dado como uma combinação:

- da direção de descida máxima e
- do deslocamento do iterado mais recente.

Especificamente, com um ponto inicial  $w^{(1)}$  e sequências de escalares  $\{\eta_k\}$  e  $\{\beta_k\}$  que são pré-determinadas ou definidas dinamicamente, estes métodos são caracterizados pela seguinte equação iterativa:

$$w^{(k+1)} = w^{(k)} - \eta_k \nabla F(w^{(k)}) + \beta_k (w^{(k)} - w^{(k-1)}) \quad (1)$$

onde  $w^{(0)} = w^{(1)}$  ( $k \geq 1$ ). O último termo é referido como o **termo de *momentum/acceralation***, o qual, de forma recursiva, mantém o movimento do algoritmo ao longo das direções de procura anteriores.

# Heavy-ball Method

- Quando  $\beta_k = 0$  para todo  $k \in \mathbb{N}$ , o método do gradiente com *momentum* reduz-se ao MDM.
- Quando  $\eta_k = \eta > 0$  e  $\beta_k = \beta > 0$  para todo  $k \in \mathbb{N}$ , obtém-se o **Heavy-ball Method**, também conhecido como **Momentum Optimization Method**:

$$w^{(k+1)} = w^{(k)} - \eta \nabla F(w^{(k)}) + \beta(w^{(k)} - w^{(k-1)}) \quad (2)$$

o qual tem, para certas funções, uma taxa de convergência superior à do MDM com um comprimento do passo  $\eta > 0$  fixo.

- $\beta \in [0, 1]$  é designado taxa de decaimento do *momentum* (*momentum decay rate*), sendo utilizado para evitar que o termo do *momentum* cresça muito.

Na prática, o valor  $\beta = 0.9$  funciona bem.

# Heavy-ball Method

Uma visão alternativa do **Heavy-ball Method** obtém-se através da expansão de (2):

$$w^{(k+1)} = w^{(k)} - \eta(\beta^{k-1}\nabla F(w^{(1)}) + \beta^{k-2}\nabla F(w^{(2)}) + \dots + \beta\nabla F(w^{(k-1)}) + \nabla F(w^{(k)}))$$

ou seja,

$$w^{(k+1)} = w^{(k)} - \eta \sum_{j=1}^k \beta^{k-j} \nabla F(w^{(j)}). \quad (3)$$

- Assim, cada passo pode ser visto como uma média exponencialmente decrescente dos gradientes anteriores. Ao escrever a iteração desta forma, observa-se que os passos tendem a acumular contribuições em direções de descida persistente, enquanto direções que oscilam tendem a anular-se, ou, pelo menos, a permanecer pequenas.



# Heavy-ball Method

- Esta interpretação fornece alguma intuição sobre o motivo pelo qual o **stochastic heavy-ball method** e, em geral, os **stochastic gradient methods with momentum** podem ser eficazes em diversos contextos. Em particular, o seu desempenho prático tornou-os populares na comunidade dedicada ao treino de redes neurais profundas.
- Substituindo o gradiente exato por um gradiente estocástico em (2), obtém-se uma iteração que, a longo prazo, tende a mover-se em direções que os gradientes estocásticos sugerem como sendo de melhoria, enquanto o movimento é limitado ao longo de direções nas quais as contribuições de vários gradientes estocásticos se anulam mutuamente.


Assim, a partir de (3), as equações iterativas do **Heavy-ball Method** podem ser reescritas na forma:

$$\begin{aligned} m^{(k+1)} &= \beta m^{(k)} - \eta \nabla F(w^{(k)}) \\ w^{(k+1)} &= w^{(k)} + m^{(k+1)} \end{aligned}$$

**Exemplo:** Comparação do desempenho do MDM e do *Heavy-ball Method* na minimização da função de Rosenbrock com  $a = 1$  e  $b = 100$ :

$$F(w_1, w_2) = (a - w_1)^2 + b(w_2 - w_1^2)^2,$$

a qual possui um minimizante global em  $w^* = (a, a^2)$ , para o qual  $F(w^*) = 0$ .



# Algoritmo do *Heavy-ball Method*

O *Heavy-ball Method* é definido pelo seguinte algoritmo iterativo.

---

## Algoritmo: *Heavy-ball Method*

---

- 1 **Entrada:**  $F$ ,  $w^{(1)}$ ,  $\eta$  (*learning rate*),  $\beta$  (*decay rate*), tolerância  $\varepsilon > 0$
  - 2 Fazer  $w^{(0)} = w^{(1)}$
  - 3 Inicializar:  $m^{(1)} = (0, 0, \dots, 0)^T$  (vetor nulo)
  - 4 Fazer  $k = 1$
  - 5 **Enquanto** ( $\|\nabla F(w^{(k)})\|_\infty > \varepsilon$ ) **fazer**
    - 6 Calcular a direção de descida:  $-\nabla F(w^{(k)})$
    - 7 Calcular o *momentum*:  $m^{(k+1)} = \beta m^{(k)} - \eta \nabla F(w^{(k)})$
    - 8 Fazer  $w^{(k+1)} = w^{(k)} + m^{(k+1)}$
    - 9 Fazer  $k = k + 1$
  - 10 **Fim enquanto**
  - 11 **Saída:**  $w^* \leftarrow w^{(k)}$ ,  $F^* \leftarrow F(w^{(k)})$  (solução ótima e valor ótimo)
-

# Nesterov's Accelerated Gradient Method

- Um das limitações do **Heavy-ball Method** é que os passos não abrandam o suficiente no fundo de um vale, tendendo a ultrapassar o mínimo.
- O **Nesterov's Accelerated Gradient (NAG) Method**, modifica-o calculando  $-\nabla F$  não no ponto atual  $w^{(k)}$  mas ligeiramente à frente na direção do *momentum*, no ponto  $w^{(k)} + \beta m^{(k)}$ .

Assim, o **NAG Method** é definido pela equação iterativa:

$$w^{(k+1)} = w^{(k)} - \eta \nabla F(w^{(k)} + \beta(w^{(k)} - w^{(k-1)})) + \beta(w^{(k)} - w^{(k-1)}). \quad (4)$$

A única diferença em relação a (2) é que o gradiente  $\nabla F$  é calculado em  $w^{(k)} + \beta(w^{(k)} - w^{(k-1)})$  em vez de em  $w^{(k)}$ .

De modo análogo, fazendo a expansão de (4) obtém-se:

$$w^{(k+1)} = w^{(k)} - \eta \sum_{j=1}^k \beta^{k-j} \nabla F(w^{(j)} + \beta m^{(j)}) \quad (5)$$

e, portanto, as equações iterativas do **método NAG** podem ser reescritas na forma:

$$\begin{aligned} m^{(k+1)} &= \beta m^{(k)} - \eta \nabla F(w^{(k)} + \beta m^{(k)}) \\ w^{(k+1)} &= w^{(k)} + m^{(k+1)} \end{aligned} \quad (6)$$

**Nota:** Neste caso, os parâmetros  $\eta$  e  $\beta$  são constantes para todo  $k$ . Contudo, podem também assumir valores distintos em cada iteração, denotados por  $\eta_k$  e  $\beta_k$ .

- Esta pequena modificação é eficaz porque, em geral, o vetor de momento aponta na direção correta (isto é, em direção ao ótimo), tornando-se assim ligeiramente mais preciso utilizar o gradiente avaliado numa posição mais avançada nessa direção, em vez do gradiente na posição original, como se pode ver na figura seguinte:




Figura: método Heavy-ball versus método NAG ( $\nabla_1$  é o gradiente da função objetivo no ponto inicial  $w^{(1)}$  e  $\nabla_2$  é o gradiente no ponto  $w^{(1)} + \beta m^{(1)}$ ).

- O método NAG é mais rápido que o método *momentum optimization*.

# Algoritmo do método NAG

O **método NAG** é definido pelo seguinte algoritmo iterativo.

---


## Algoritmo: método NAG

---

- ➊ **Entrada:**  $F$ ,  $w^{(1)}$ ,  $\eta$  (*learning rate*),  $\beta$  (*decay rate*), tolerância  $\varepsilon > 0$
  - ➋ Fazer  $w^{(0)} = w^{(1)}$
  - ➌ Inicializar:  $m^{(1)} = (0, 0, \dots, 0)^T$  (vetor nulo)
  - ➍ Fazer  $k = 1$
  - ➎ **Enquanto**  $(\|\nabla F(w^{(k)})\|_{\infty} > \varepsilon)$  **fazer**
    - ➏ Calcular a direção de descida no ponto:  $-\nabla F(w^{(k)} + \beta m^{(k)})$
    - ➐ Calcular o *momentum*:  $m^{(k+1)} = \beta m^{(k)} - \eta \nabla F(w^{(k)} + \beta m^{(k)})$
    - ➑ Fazer  $w^{(k+1)} = w^{(k)} + m^{(k+1)}$
    - ➒ Fazer  $k = k + 1$
  - ➓ **Fim enquanto**
  - ➑ **Saída:**  $w^* \leftarrow w^{(k)}$ ,  $F^* \leftarrow F(w^{(k)})$  (solução ótima e valor ótimo)
-

**Exemplo:** Comparação do desempenho do método NAG e do método *Heavy-ball* na minimização da função de Rosenbrock com  $a = 1$  e  $b = 100$ :

$$F(w_1, w_2) = (a - w_1)^2 + b(w_2 - w_1^2)^2$$



— método NAG; — método *momentum optimization*.

- Todos os algoritmos de otimização em aprendizagem profunda baseiam-se em mecanismos de *momentum/acceleration*, como **RMSprop**, **AdaGrad**, **Adam**, etc.
- <https://distill.pub/2017/momentum/>